

École Nationale des Sciences Appliquées- AL Hoceima

Filière : Ingénierie des Données

Deuxième Année

Mini-Projet : Transformers et Systèmes RAG

1 Partie 1 : Exploration des Transformers et tâches NLP

Objectif

Cette partie vise à familiariser les étudiants avec l'utilisation pratique des modèles Transformers pour différentes tâches NLP, en s'appuyant sur la bibliothèque HuggingFace Transformers et un ouvrage de référence fourni.

Travail demandé

- Exploration de la bibliothèque HuggingFace Transformers :
 - Chargement de modèles pré-entraînés
 - Utilisation de tokenizers
 - Pipelines simplifiés pour tâches NLP
- Implémentation de plusieurs tâches NLP :
 - Classification de texte
 - Analyse de sentiment
 - Question Answering
 - Résumé automatique

2 Partie 2 : Systèmes RAG (Retrieval-Augmented Generation)

Objectif

Comprendre, analyser et implémenter un système RAG permettant d'améliorer les capacités des modèles de langage en intégrant une étape de récupération d'information externe.

Travail demandé

1. *État de l'art*

Les étudiants doivent présenter :

- Définition des systèmes RAG
- Limites des LLMs sans accès à des données externes
- Comparaison des approches :
 - Fine-tuning
 - Prompt engineering
 - RAG
- Aperçu des variantes modernes des architectures RAG

2. *Architecture et pipeline*

Décrire et formaliser le pipeline complet d'un système RAG :

1. Encodage des documents sous forme d'embeddings
2. Indexation de la base de connaissances
3. Encodage de la requête utilisateur
4. Recherche des top-k documents pertinents
5. Construction du prompt augmenté
6. Génération de la réponse par le LLM

3. *Implémentation*

Les étudiants doivent implémenter un système RAG simple comprenant :

- Un corpus de documents (PDF, articles ou dataset simplifié)
- Un modèle d'embeddings (ex : sentence-transformers)
- Un moteur de recherche vectoriel (FAISS ou équivalent)
- Un modèle génératif (API ou modèle local)

4. Démonstration et expérimentation

Le système doit être testé avec :

- Des questions sur le corpus
- Une comparaison entre réponses avec et sans RAG

Livrables

- Rapport PDF structuré et bien présenté
- Code source (Notebook ou projet Python)
- Démonstration fonctionnelle du système RAG

Bon travail